

模型是在信任对方，还是在相信自己能控制风险？

V4 里出现了一个有意思的分离：机会主义者的信任评分不高，但在某些条件下模型仍愿意支付入场费。V5 专门检验这个机制：模型是否认为“我不信任你，但我能预测你什么时候会背叛，所以我还愿意进场”。

实验动机

V1-V4 的主线是：模型在重复信任博弈里总体更依赖实际行为，而不是漂亮话。但 V4 进一步暴露了一个更微妙的问题：信任评分和愿意支付的入场费并不总是同向变化。

V4 的问题

机会主义者在高赌注时少返还，因此信任评分低于稳定合作者；但它在低赌注时返还高，模型可能觉得这类对象虽然“不可靠”，但“可预测、可规避、可利用”。

V5 的核心想法

如果模型真的形成了这种策略性判断，那么当它能控制下一轮赌注大小时，应该愿意为机会主义者支付更高入场费；当下一轮被固定为高赌注时，它应该退出或显著降价。

一句话研究问题：大语言模型面对机会主义对象时，是在“信任对方”，还是在“相信自己能预测并控制对方的背叛触发条件”？

假设

H1：信任和可控性分离

可预测机会主义者的信任评分应低于稳定合作者，但在可控赌注条件下仍可能获得较高入场费。

H2：可控性溢价

可预测机会主义者的 $WTP_{controllable} - WTP_{fixed_high}$ 应明显高于稳定合作者。

H3：不是单纯风险偏好

随机机会主义者和可预测机会主义者有相近平均返还和波动，但低返还不和赌注绑定。如果模型追求的是可预测性，两者应表现不同。

H4：策略性避险

在可控赌注条件下，模型面对可预测机会主义者应主动选择低赌注，避开会触发低返还的高赌注。

实验设计

V5 使用 3×3 设计：三类对象 $\times$ 三类控制权。每类对象有 6 段数值历史，每段历史有 6 轮；总共 54 个 trial，成功解析 51 个。

变量	水平	设计目的
对象类型	稳定合作者	各赌注返还稳定在 0.40 左右，作为高信任基线。
对象类型	可预测机会主义者	低赌注返还高，高赌注返还低；平均返还仍控制在 0.40。
对象类型	随机机会主义者	平均返还和波动与机会主义者接近，但低返还不和赌注大小绑定。
控制权	可控赌注	模型付入场费后可以自己选择低、中、高赌注。
控制权	固定高赌注	模型付入场费后下一轮一定是高赌注。
控制权	随机赌注	模型付入场费后由系统随机决定低、中、高赌注。

关键控制：三类对象的平均返还都控制在 0.40 左右。可预测机会主义者和随机机会主义者的波动幅度也接近，二者主要区别是：低返还是否系统性地绑定在高赌注上。

方法

模型看到什么

每个 trial 中，模型看到同一对象过去 6 轮互动记录。每轮包括赌注大小、前一位参与者投入多少、对方收到多少、对方实际返还多少。语言固定为中性句子，避免再混入漂亮话或道歉。

模型回答什么

模型输出是否继续互动、愿意支付的入场费、信任评分、对低/中/高赌注的预期返还。在可控赌注条件下，它还要选择下一轮是低、中还是高赌注。

51/54

成功试次

3 个试次解析失败，未重试；以下结果基于成功试次。

0.4

平均返还

所有对象的总体平均返还被控制在 0.40 左右。

1.333

平均入场费

入场费来自模型输出的 willingness_to_pay，范围 0-10。

51.451

平均信任

信任评分来自模型输出的 trust_rating，范围 0-100。

主要结果

结果 1：模型准确识别“低赌注高返还、高赌注低返还”的结构

可预测机会主义者的实际低-高赌注返还差为 0.305，模型预测的低-高赌注返还差为 0.303。也就是说，模型不仅看到了机会主义，而且把它表征成了一个和赌注大小相关的规则。

结果 2：可控性让可预测机会主义者从“完全不值得进场”变成“值得付费尝试”

对可预测机会主义者，固定高赌注时 WTP 为 0，继续率为 0，投资比例为 0；可控赌注时 WTP 升到 2，继续率升到 1。

结果 3：可预测机会主义者的可控性溢价最大

对象类型	可控赌注 WTP	固定高赌注 WTP	随机赌注 WTP	可控性溢价
稳定合作者	1.6	1.5	1	0.1
可预测机会主义者	2	0	1	2
随机机会主义者	2.333	1.333	1	1

可预测机会主义者的可控性溢价为 +2.00；稳定合作者几乎没有溢价，只有 +0.10。这正是“我不是更信任你，而是我觉得我能控制风险”的结果模式。

结果 4：可控条件下，模型面对可预测机会主义者全部选择低赌注

在可控赌注条件中，可预测机会主义者 6/6 都被模型选择为低赌注。稳定合作者则主要选择高赌注；随机机会主义者的选择分散在低、中、高之间。




图1：入场费不是单纯的信任，而是对下一轮机会的定价。

结果上，可预测机会主义者在“可控赌注”条件下的平均 WTP 为 2.00；同一个对象一旦进入“固定高赌注”条件，WTP 降到 0。稳定合作者在三个条件下都没有这种断崖式变化；随机机会主义者也会因为可控性获得更高 WTP，但没有形成同样清楚的低赌注策略。

这说明模型不是简单地“喜欢”或“信任”机会主义者。更贴切的解释是：当它能控制赌注大小时，它愿意买入一个可以被利用的机会；当它被迫进入高赌注时，它知道这个机会主义者会变危险，于是退出。




图2：信任评分仍然保留了对“这个对象靠不靠谱”的整体判断。

结果上，稳定合作者整体信任评分最高；可预测机会主义者在固定高赌注下信任最低。可控赌注会提高可预测机会主义者的评分，但它仍然不是稳定合作者那种无条件可靠对象。

这张图提醒我们，trust rating 和 WTP 不是同一个心理量。trust rating 更像整体可靠性评价；WTP 更像“是否值得进入下一轮”的行动价格。V5 的价值正在于把这两者分开：模型可以不完全信任一个对象，但仍然愿意为可控互动付费。




图3：可控性溢价显示“我能控制局面”本身有价值。

这里的可控性溢价定义为：可控赌注条件下的 WTP 减去固定高赌注条件下的 WTP。可预测机会主义者的溢价最大，为 +2.00；稳定合作者几乎没有溢价，只有 +0.10；随机机会主义者也有 +1.00。

最关键的比较不是“机会主义者 WTP 是否高”，而是“同一个机会主义者在可控和不可控时差多少”。这个差值说明模型在付费购买控制权。不过随机机会主义者也有正溢价，意味着控制权有一般吸引力；后续正式实验需要进一步区分一般 control value 和针对可预测机会主义的特殊策略价值。




图4：模型确实识别了可预测机会主义者的“触发规则”。

低-高预测差表示模型预测“低赌注返还”比“高赌注返还”高多少。可预测机会主义者的预测差约为 +0.303，几乎贴近真实结构；稳定合作者和随机机会主义者接近 0。

这张图是机制证据。没有它，图1 的 WTP 差异可能只是一般风险偏好或随机波动；有了它，我们可以说模型不仅记住了平均返还，还表征了 partner policy：这个对象在什么条件下会合作、在什么条件下会背叛。




图5：真正的行为证据是模型在可控时如何下注。

只看可控赌注条件，模型面对可预测机会主义者时 6/6 选择低赌注；面对稳定合作者时主要选择高赌注；面对随机机会主义者时选择更分散。

这直接对应你刚才提到的机制：“我赌我能猜到多高的赌注会触发你的低返还。”模型不是盲目冒险，也不是只看漂亮话；它在有控制权时主动把互动推到对自己有利的低赌注区域。这也是 V5 最适合继续展开成论文 story 的部分。

完整结果表

对象	控制权	N	实际低-高	预测低-高	信任	WTP	投资比例
稳定合作者	可控赌注	5/6	0.014	0.012	74	1.6	1
稳定合作者	固定高赌注	6/6	0.013	0.013	51.667	1.5	1
稳定合作者	随机赌注	6/6	0.013	0.012	59.167	1	1
可预测机会主义者	可控赌注	6/6	0.305	0.303	61.333	2	1
可预测机会主义者	固定高赌注	5/6	0.305	0.303	33.2	0	0
可预测机会主义者	随机赌注	5/6	0.305	0.305	44	1	0.667
随机机会主义者	可控赌注	6/6	-0.012	-0.008	54.167	2.333	1
随机机会主义者	固定高赌注	6/6	-0.012	-0.014	44.167	1.333	0.667
随机机会主义者	随机赌注	6/6	-0.012	-0.014	40.833	1	0.778

结论

V5 支持一个比“模型信不信漂亮话”更细的解释：模型会把对方是否可信和互动是否可控分开。

主结论：可预测机会主义者在固定高赌注下不值得进入，但在模型可以控制赌注时重新变得有价值。模型不是单纯更信任机会主义者，而是在利用“可预测的坏”。

理论含义

这说明大模型的社会决策输出中可能至少有两个维度：一是 moral trust，即对方是否可靠；二是 strategic controllability，即对方虽不可靠但是否可预测、可规避、可利用。

和 V4 的关系

V4 中“机会主义者低信任但 WTP 不低”的结果，在 V5 得到了更清楚的机制解释：高 WTP 不是因为模型更信任它，而是因为模型认为只要能避开高赌注，就能把风险控制住。

不足和下一步

样本还小

每个 cell 只有 5-6 个成功试次。当前结果足够做 pilot，但正式论文需要扩大 trial 数，并补齐 3 个失败项。

单模型结果

当前只跑了 MiniMax-M2.7。下一步至少应复现到多个模型，尤其检查不同模型是否都表现出可控性溢价。

random opportunist 也有控制权收益

随机机会主义者在可控条件下 WTP 也升高，说明控制权本身有一般价值。正式分析应区分“一般控制权收益”和“可预测机会主义的特异收益”。

需要更严格统计

后续应使用混合效应模型或 Bayesian hierarchical model，检验 partner type × control condition 交互，而不是只看均值。